Zookeeper

Zookeeper

1. Zookeeper概念简介：

Zookeeper是一个分布式协调服务；就是为用户的分布式应用程序提供协调服务
A、zookeeper是为别的分布式程序服务的
B、Zookeeper本身就是一个分布式程序（只要有半数以上节点存活，zk就能正常服务）C、Zookeeper所提供的服务涵盖：主从协调、服务器节点动态上下线、统一配置管理、分布式共享锁、统一名称服务……
D、虽然说可以提供各种服务，但是zookeeper在底层其实只提供了两个功能：
管理(存储，读取)用户程序提交的数据； 并为用户程序提供数据节点监听服务； Zookeeper集群的角色： Leader 和 follower （Observer）只要集群中有半数以上节点存活，集群就能提供服务

2. zookeeper集群机制

半数机制：集群中半数以上机器存活，集群可用。 zookeeper适合装在奇数台机器上！！！

3. 安装

3.1. 安装

3.1.1. 机器部署

安装到3台虚拟机上 安装好JDK

3.1.2. 上传

上传用工具。

3.1.3. 解压

su – hadoop（切换到hadoop用户） tar -zxvf zookeeper-3.4.5.tar.gz（解压）

3.1.4. 重命名

mv zookeeper-3.4.5 zookeeper（重命名文件夹zookeeper-3.4.5为zookeeper）

3.1.5. 修改环境变量

1、su – root(切换用户到root)
2、vi /etc/profile(修改文件)
3、添加内容：

export ZOOKEEPER_HOME=/home/hadoop/zookeeper export PATH=$PATH:$ZOOKEEPER_HOME/bin

4、刷新：

source /etc/profile

5、注意：3台zookeeper都需要修改

6、修改完成后切换回hadoop用户：

su - hadoop

3.1.6. 修改配置文件

1、用hadoop用户操作

cd zookeeper/conf cp zoo_sample.cfg zoo.cfg

2、vi zoo.cfg

3、添加内容：

dataDir=/home/hadoop/zookeeper/data dataLogDir=/home/hadoop/zookeeper/log
server.1=slave1:2888:3888 (主机名, 心跳端口、数据端口) server.2=slave2:2888:3888
server.3=slave3:2888:3888

4、创建文件夹：

cd /home/hadoop/zookeeper/ mkdir -m 755 data mkdir -m 755 log

5、在data文件夹下新建myid文件，myid的文件内容为：

cd data vi myid 添加内容： 1

3.1.7. 将集群下发到其他机器上

scp -r /home/hadoop/zookeeper hadoop@slave2:/home/hadoop/ scp -r /home/hadoop/zookeeper
hadoop@slave3:/home/hadoop/

3.1.8. 修改其他机器的配置文件

到slave2上：修改myid为：2 到slave3上：修改myid为：3

3.1.9. 启动（每台机器）

zkServer.sh start

3.1.10. 查看集群状态

1、 jps（查看进程） 2、 zkServer.sh status（查看集群状态，主从信息）

4. zookeeper结构和命令

4.1. zookeeper特性

1、Zookeeper：一个leader，多个follower组成的集群

2、全局数据一致：每个server保存一份相同的数据副本，client无论连接到哪个server，数据都是一致的

3、分布式读写，更新请求转发，由leader实施

4、更新请求顺序进行，来自同一个client的更新请求按其发送顺序依次执行

5、数据更新原子性，一次数据更新要么成功，要么失败

6、实时性，在一定时间范围内，client能读到最新数据

4.2. zookeeper数据结构

1、层次化的目录结构，命名符合常规文件系统规范(见下图)

2、每个节点在zookeeper中叫做znode,并且其有一个唯一的路径标识

3、节点Znode可以包含数据和子节点（但是EPHEMERAL类型的节点不能有子节点，下一页详细讲解）

4、客户端应用可以在节点上设置监视器（后续详细讲解）

4.3. 数据结构的图

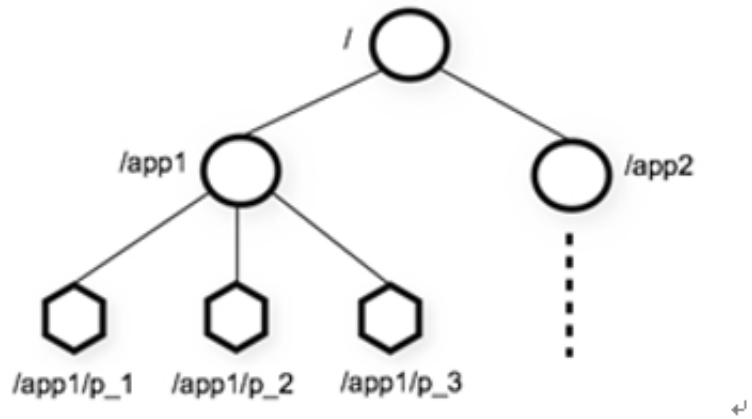

4.4. 节点类型

1、Znode有两种类型：

短暂（ephemeral）（断开连接自己删除） 持久（persistent）（断开连接不删除）

2、Znode有四种形式的目录节点（默认是persistent ）

PERSISTENT PERSISTENT_SEQUENTIAL（持久序列/test0000000019 ） EPHEMERAL EPHEMERAL_SEQUENTIAL

3、创建znode时设置顺序标识，znode名称后会附加一个值，顺序号是一个单调递增的计数器，由父节点维护

4、在分布式系统中，顺序号可以被用于为所有的事件进行全局排序，这样客户端可以通过顺序号推断事件的顺序

4.5. zookeeper命令行操作

运行 zkCli.sh –server 进入命令行工具

1、使用 ls 命令来查看当前 ZooKeeper 中所包含的内容：

[zk: 202.115.36.251:2181(CONNECTED) 1] ls /

2、创建一个新的 znode ，使用 create /zk myData 。这个命令创建了一个新的 znode 节点“ zk ”以及与它关联的字符串：

[zk: 202.115.36.251:2181(CONNECTED) 2] create /zk "myData“

3、我们运行 get 命令来确认 znode 是否包含我们所创建的字符串：

[zk: 202.115.36.251:2181(CONNECTED) 3] get /zk 监听这个节点的变化,当另外一个客户端改变/zk时,它会打出下面的 WATCHER:: WatchedEvent state:SyncConnected type:NodeDataChanged path:/zk [zk: localhost:2181(CONNECTED) 4] get /zk watch

4、下面我们通过 set 命令来对 zk 所关联的字符串进行设置：

[zk: 202.115.36.251:2181(CONNECTED) 4] set /zk "zsl“

5、下面我们将刚才创建的 znode 删除：

[zk: 202.115.36.251:2181(CONNECTED) 5] delete /zk

6、删除节点：rmr

[zk: 202.115.36.251:2181(CONNECTED) 5] rmr /zk

4.6. zookeeper-api应用

4.6.1. 基本使用

org.apache.zookeeper.Zookeeper是客户端入口主类，负责建立与server的会话 它提供了表 1 所示几类主要方法 ：

```
??    ??
create    ????????????
delete    ??????
exists    ???????????
get/set data    ???????? / ???
get/set ACL    ?? / ?????????????
get children    ??????????
sync    ?????????
```

4.6.2. demo增删改查

```
public class SimpleDemo {
    // ?????????????????
    private static final int SESSION_TIMEOUT = 30000;
    // ?? ZooKeeper ??
    ZooKeeper zk;
    // ?? Watcher ??
    Watcher wh = new Watcher() {
        public void process(org.apache.zookeeper.WatchedEvent event)
        {
            System.out.println(event.toString());
        }
    };
    // ??? ZooKeeper ??
    private void createZKInstance() throws IOException
    {
        zk = new ZooKeeper("weekend01:2181", SimpleDemo.SESSION_TIMEOUT, this.wh);
    }
    private void ZKOperations() throws IOException, InterruptedException, KeeperExcep
tion
    {
        System.out.println("/n1. ?? ZooKeeper ?? (znode ? zoo2, ??? myData2 ???? OPEN
_ACL_UNSAFE ?????? Persistent");
        zk.create("/zoo2", "myData2".getBytes(), Ids.OPEN_ACL_UNSAFE, CreateMode.PERS
ISTENT);
        System.out.println("/n2. ????????? ");
        System.out.println(new String(zk.getData("/zoo2", false, null)));
        System.out.println("/n3. ?????? ");
        zk.setData("/zoo2", "shenlan211314".getBytes(), -1);
        System.out.println("/n4. ????????? ");
        System.out.println(new String(zk.getData("/zoo2", false, null)));
```

```
        System.out.println("/n5. ???? ");
        zk.delete("/zoo2", -1);
        System.out.println("/n6. ?????????? ");
        System.out.println(" ????? [" + zk.exists("/zoo2", false) + "]");
    }
    private void ZKClose() throws InterruptedException
    {
        zk.close();
    }
    public static void main(String[] args) throws IOException, InterruptedException,
KeeperException {
        SimpleDemo dm = new SimpleDemo();
        dm.createZKInstance();
        dm.ZKOperations();
        dm.ZKClose();
    }
}
```

Zookeeper的监听器工作机制

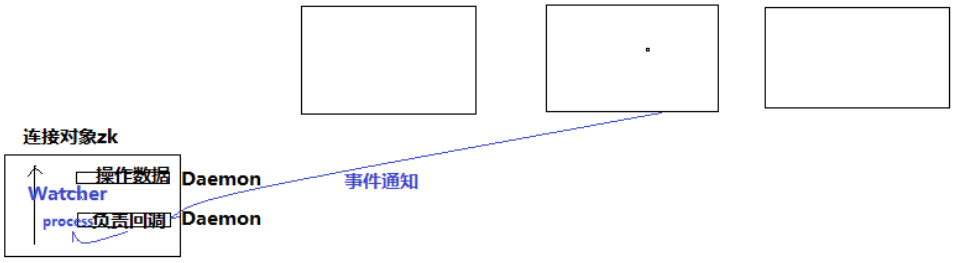

监听器是一个接口，我们的代码中可以实现Wather这个接口，实现其中的process方法，方法中即我们自己的业务逻辑

监听器的注册是在获取数据的操作中实现： getData(path,watch?)监听的事件是：节点数据变化事件
getChildren(path,watch?)监听的事件是：节点下的子节点增减变化事件

4.7. zookeeper应用案例（分布式应用HA||分布式锁）

3.7.1 实现分布式应用的(主节点HA)及客户端动态更新主节点状态

某分布式系统中，主节点可以有多台，可以动态上下线 任意一台客户端都能实时感知到主节点服务器的上下线

A、客户端实现

```
public class AppClient {
    private String groupNode = "sgroup";
    private ZooKeeper zk;
    private Stat stat = new Stat();
    private volatile List serverList;
    /**
     * ??zookeeper
     */
    public void connectZookeeper() throws Exception {
        zk = new ZooKeeper("localhost:4180,localhost:4181,localhost:4182", 5000, new
Watcher() {
            public void process(WatchedEvent event) {
                // ?????"/sgroup"???????????, ??server??, ???????
                if (event.getType() == EventType.NodeChildrenChanged
                    && ("/" + groupNode).equals(event.getPath())) {
                    try {
                        updateServerList();
                    } catch (Exception e) {
                        e.printStackTrace();
                    }
                }
            }
        });

        updateServerList();
    }
    /**
     * ??server??
     */
    private void updateServerList() throws Exception {
        List newServerList = new ArrayList();

        // ?????groupNode??????
        // watch???true, ???????????.
        // ???????????, ??????, ????????, ??????????, ??????
        List subList = zk.getChildren("/" + groupNode, true);
        for (String subNode : subList) {
            // ???????????server??
            byte[] data = zk.getData("/" + groupNode + "/" + subNode, false, stat);
            newServerList.add(new String(data, "utf-8"));
        }

        // ??server??
        serverList = newServerList;

        System.out.println("server list updated: " + serverList);
    }

    /**
     * client???????????
```

```
     * ????????, ??client sleep
     */
    public void handle() throws InterruptedException {
        Thread.sleep(Long.MAX_VALUE);
    }

    public static void main(String[] args) throws Exception {
        AppClient ac = new AppClient();
        ac.connectZookeeper();

        ac.handle();
    }
}
```

B、服务器端实现

```
public class AppServer {
private String groupNode = "sgroup";
private String subNode = "sub";
/**
 * ??zookeeper
 * @param address server???
 */
public void connectZookeeper(String address) throws Exception {
    ZooKeeper zk = new ZooKeeper(
"localhost:4180,localhost:4181,localhost:4182",
5000, new Watcher() {
        public void process(WatchedEvent event) {
            // ????
        }
    });
    // ?"/sgroup"??????
    // ?????????EPHEMERAL_SEQUENTIAL, ??????????, ??    ???????????????
    // ?server???????????????
    String createdPath = zk.create("/" + groupNode + "/" + subNode, address.getBytes(
"utf-8"),
        Ids.OPEN_ACL_UNSAFE, CreateMode.EPHEMERAL_SEQUENTIAL);
    System.out.println("create: " + createdPath);
}
/**
 * server???????????
 * ????????, ??server sleep
 */
public void handle() throws InterruptedException {
    Thread.sleep(Long.MAX_VALUE);
}
public static void main(String[] args) throws Exception {
    // ??????server???
    if (args.length == 0) {
        System.err.println("The first argument must be server             address");
        System.exit(1);
    }
    AppServer as = new AppServer();
    as.connectZookeeper(args[0]);
```

```
    as.handle();
}



}
```

3.7.2分布式共享锁的简单实现

客户端A

```
public class DistributedClient {
    // ????
    private static final int SESSION_TIMEOUT = 5000;
    // zookeeper server??
    private String hosts = "localhost:4180,localhost:4181,localhost:4182";
    private String groupNode = "locks";
    private String subNode = "sub";
    private ZooKeeper zk;
    // ??client??????
    private String thisPath;
    // ??client??????
    private String waitPath;
    private CountDownLatch latch = new CountDownLatch(1);
    /**
     * ??zookeeper
     */
    public void connectZookeeper() throws Exception {
        zk = new ZooKeeper(hosts, SESSION_TIMEOUT, new Watcher() {
            public void process(WatchedEvent event) {
                try {
                    // ?????, ??latch, ??wait??latch????
                    if (event.getState() == KeeperState.SyncConnected) {
                        latch.countDown();
                    }

                    // ???waitPath?????
                    if (event.getType() == EventType.NodeDeleted && event.getPath().e
quals(waitPath)) {
                        doSomething();
                    }
                } catch (Exception e) {
                    e.printStackTrace();
                }
            }
        });

        // ??????
        latch.await();

        // ?????
        thisPath = zk.create("/" + groupNode + "/" + subNode, null, Ids.OPEN_ACL_UNSA
FE,
                CreateMode.EPHEMERAL_SEQUENTIAL);
```

```
        // wait???, ????????
        Thread.sleep(10);

        // ??, ??????"/locks"?????????
        List childrenNodes = zk.getChildren("/" + groupNode, false);

        // ??????????, ?????thisPath, ??client???
        if (childrenNodes.size() == 1) {
            doSomething();
        } else {
            String thisNode = thisPath.substring(("/" + groupNode + "/").length());
            // ??
            Collections.sort(childrenNodes);
            int index = childrenNodes.indexOf(thisNode);
            if (index == -1) {
                // never happened
            } else if (index == 0) {
                // inddx == 0, ??thisNode??????, ??client???
                doSomething();
            } else {
                // ?????thisPath?1????
                this.waitPath = "/" + groupNode + "/" + childrenNodes.get(index - 1);
                // ?waitPath??????, ?waitPath????, zookeeper???????process??
                zk.getData(waitPath, true, new Stat());
            }
        }
    }

    private void doSomething() throws Exception {
        try {
            System.out.println("gain lock: " + thisPath);
            Thread.sleep(2000);
            // do something
        } finally {
            System.out.println("finished: " + thisPath);
            // ?thisPath??, ??thisPath?client?????
            // ??????
            zk.delete(this.thisPath, -1);
        }
    }

    public static void main(String[] args) throws Exception {
        for (int i = 0; i < 10; i++) {
            new Thread() {
                public void run() {
                    try {
                        DistributedClient dl = new DistributedClient();
                        dl.connectZookeeper();
                    } catch (Exception e) {
                        e.printStackTrace();
                    }
                }
            }.start();
        }
```

```
        Thread.sleep(Long.MAX_VALUE);
    }
}
```

分布式多进程模式实现：

```
public class DistributedClientMy {
// ????
private static final int SESSION_TIMEOUT = 5000;
// zookeeper server??
private String hosts = "spark01:2181,spark02:2181,spark03:2181";
private String groupNode = "locks";
private String subNode = "sub";
private boolean haveLock = false;

private ZooKeeper zk;
// ??client??????
private volatile String thisPath;

/**
 * ??zookeeper
 */
public void connectZookeeper() throws Exception {
    zk = new ZooKeeper("spark01:2181", SESSION_TIMEOUT, new Watcher() {
        public void process(WatchedEvent event) {
            try {

                // ???????
                if (event.getType() == EventType.NodeChildrenChanged && event.getPath
().equals("/" + groupNode)) {
                    // thisPath???????????
                    List childrenNodes = zk.getChildren("/" + groupNode, true);
                    String thisNode = thisPath.substring(("/" + groupNode + "/").leng
th());
                    // ??
                    Collections.sort(childrenNodes);
                    if (childrenNodes.indexOf(thisNode) == 0) {
                        doSomething();
                        thisPath = zk.create("/" + groupNode + "/" + subNode, null, I
ds.OPEN_ACL_UNSAFE,
                                CreateMode.EPHEMERAL_SEQUENTIAL);
                    }
                }
            } catch (Exception e) {
                e.printStackTrace();
            }
        }
    });

    // ?????
    thisPath = zk.create("/" + groupNode + "/" + subNode, null, Ids.OPEN_ACL_UNSAFE,
            CreateMode.EPHEMERAL_SEQUENTIAL);
```

```
    // wait???, ????????
    Thread.sleep(new Random().nextInt(1000));

    // ????????
    List childrenNodes = zk.getChildren("/" + groupNode, true);

    // ??????????, ?????thisPath, ??client???
    if (childrenNodes.size() == 1) {
        doSomething();
        thisPath = zk.create("/" + groupNode + "/" + subNode, null, Ids.OPEN_ACL_UNSA
FE,
                CreateMode.EPHEMERAL_SEQUENTIAL);
    }
}

/**
 * ???????????????
 */
private void doSomething() throws Exception {
    try {
        System.out.println("gain lock: " + thisPath);
        Thread.sleep(2000);
        // do something
    } finally {
        System.out.println("finished: " + thisPath);
        // ?thisPath??, ??thisPath?client?????
        // ??????
        zk.delete(this.thisPath, -1);
    }
}

public static void main(String[] args) throws Exception {
    DistributedClientMy dl = new DistributedClientMy();
    dl.connectZookeeper();
    Thread.sleep(Long.MAX_VALUE);
}



}
```

动手练习

5. zookeeper原理

Zookeeper虽然在配置文件中并没有指定master和slave
但是，zookeeper工作时，是有一个节点为leader，其他则为follower Leader是通过内部的选举机制临时产生的

5.1. zookeeper的选举机制（全新集群paxos）

以一个简单的例子来说明整个选举的过程. 假设有五台服务器组成的zookeeper集群,它们的id从1-5,同时它们都是最新启动的,也就是没有历史数据,在存放数据量这一点上,都是一样的.假设这些服务器依序启动,来看看会发生什么. 1) 服务器1启动,此时只有它一台服务器启动了,它发出去的报没有任何响应,所以它的选举状态一直是LOOKING状态 2) 服务器2启动,它与最开始启动的服务器1进行通信,互相交换自己的选举结果,由于两者都没有历史数据,所以id值较大的服

务器2胜出,但是由于没有达到超过半数以上的服务器都同意选举它(这个例子中的半数以上是3),所以服务器1,2还是继续保持LOOKING状态. 3) 服务器3启动,根据前面的理论分析,服务器3成为服务器1,2,3中的老大,而与上面不同的是,此时有三台服务器选举了它,所以它成为了这次选举的leader. 4) 服务器4启动,根据前面的分析,理论上服务器4应该是服务器1,2,3,4中最大的,但是由于前面已经有半数以上的服务器选举了服务器3,所以它只能接收当小弟的命了. 5) 服务器5启动,同4一样,当小弟.

5.2. 非全新集群的选举机制(数据恢复)

那么，初始化的时候，是按照上述的说明进行选举的，但是当zookeeper运行了一段时间之后，有机器down掉，重新选举时，选举过程就相对复杂了。 需要加入数据id、leader id和逻辑时钟。
数据id：数据新的id就大，数据每次更新都会更新id。 Leader id：就是我们配置的myid中的值，每个机器一个。
逻辑时钟：这个值从0开始递增,每次选举对应一个值,也就是说: 如果在同一次选举中,那么这个值应该是一致的；
逻辑时钟值越大,说明这一次选举leader的进程更新. 选举的标准就变成：
1、逻辑时钟小的选举结果被忽略，重新投票 2、统一逻辑时钟后，数据id大的胜出 3、数据id相同的情况下，leader id大的胜出 根据这个规则选出leader。